



COMPUTACIÓN DE ALTO DESEMPEÑO



Predicción de la Calidad del Agua en la India

Tratamiento de datos y Machine Learning con PySpark sobre Apache Spark y Hadoop HDFS

Jesús David Romero Melo

Facultad de Ingeniería · Pontificia Universidad Javeriana

28 de mayo de 2026

El agua potable como reto de salud pública

El acceso al agua potable es un derecho humano fundamental e indicador del desarrollo de una nación.

En India —más de 1.400 millones de habitantes y una red hídrica de gran complejidad geográfica— el monitoreo y la predicción de la calidad del agua son un desafío sanitario de primer orden.

Los datos provienen del sistema oficial RiverIndia (CPCB), con mediciones de 534 estaciones distribuidas en el territorio nacional.



Índice de Calidad del Agua (WQI)

Métrica compuesta que sintetiza el estado sanitario del recurso hídrico en un único valor numérico, facilitando la decisión de las autoridades.

8 PARÁMETROS FÍSICOQUÍMICOS Y MICROBIOLÓGICOS

TEMP Temperatura (°C)	DO Oxígeno disuelto (mg/L)
pH Potencial de hidrógeno	CONDUCTIVITY Conductividad (µS/cm)
BOD Demanda bioq. de O ₂ (mg/L)	NITRATE/NITRITE Nitratos y nitritos (mg/L)
FECAL COLIFORM Coliformes fecales	TOTAL COLIFORM Coliformes totales

Qué buscamos lograr

OBJETIVO GENERAL



Implementar y comparar modelos de Machine Learning para predecir el WQI en ríos de la India usando Apache Spark, evaluando su rendimiento con métricas estándar.

OBJETIVOS ESPECÍFICOS



Cargar y preprocesar datos de calidad del agua desde Hadoop HDFS con PySpark.



Realizar análisis exploratorio: estadísticas, nulos y visualización geoespacial.



Calcular el WQI como variable objetivo a partir de los sub-índices de cada parámetro.



Entrenar y evaluar tres modelos: Red Neuronal, Random Forest y GBT.




Comparar precisión (RMSE, R^2) y eficiencia computacional (tiempo de entrenamiento).



Analizar las implicaciones de cada modelo en el procesamiento distribuido.

Pipeline de procesamiento en Spark



Tres enfoques de aprendizaje



Red Neuronal

Keras

- Feedforward: entrada de 6 features
- 3 capas ocultas densas (350 ReLU)
- Optimizador Adam · 200 épocas
- Entrena fuera de Spark (.toPandas)



Random Forest

Spark MLlib

- Ensamble de 100 árboles paralelos
- Muestreo y subselección por nodo
- Predicción = promedio de árboles
- Integración nativa y eficiente en Spark




Gradient Boosted Trees

Spark MLlib

- Ensamble secuencial (maxIter=100)
- Cada árbol corrige el residual previo
- No paralelizable, pero más preciso
- Opera nativamente sobre DataFrames

Resultados comparativos

PRECISIÓN: R² Y RMSE EN PRUEBA



RMSE TEST · TIEMPO DE ENTRENAMIENTO (s)




TABLA DE RESULTADOS

Modelo	RMSE Tr.	RMSE Test	R² Test	Tiempo (s)
Red Neuronal (Keras)	0.0228	0.23	0.9998	6.49
Random Forest (MLlib)	4.270	5.2929	0.9053	1.25
GBT (MLlib)	0.107	3.5074	0.9849	17.80



Mejor precisión Red Neuronal — $R^2 = 0.9998$, se evidencia un leve sobreajuste



Más rápido Random Forest — solo 1.25 s, paralelizable



Mejor para producción Random Forest — Modelo más honesto + rápido + alta precisión + integración nativa Spark

Hallazgos clave



Alta precisión generalizada

Los tres modelos superan $R^2 > 0.92$: el WQI es una función matemática ponderada de los mismos sub-índices usados como features.



Ventaja de la red en funciones continuas

Las neuronas ReLU aproximan mejor las relaciones suaves del WQI que las fronteras escalonadas de los árboles.



Limitación crítica de la red en procesamiento distribuido

`.toPandas()` colapsa todos los datos en un único nodo — un cuello de botella severo a escala de millones de registros.



RF y GBT, distribuidos de extremo a extremo

Operan nativamente sobre DataFrames de Spark en todo el pipeline, garantizando escalabilidad real.



MLlib carece de red neuronal de regresión

Solo existe `MultilayerPerceptronClassifier` (clasificación), inaplicable a una variable continua como el WQI.



Idea de fondo

La elección del modelo en alto volumen de datos no depende solo de la precisión, sino de su encaje con la arquitectura distribuida.

Hacia una solución escalable

Para producción distribuida



Usar Random Forest como modelo principal: mejor balance entre precisión, honestidad, tiempo e integración nativa con Spark, escalando sin cambios ante grandes volúmenes.

Para la red neuronal



Si se requiere Keras en producción, distribuir la inferencia con Pandas UDF para preservar la escalabilidad en esa etapa del pipeline.

Para trabajo futuro



Explorar añadir regularización al modelo GBT para bajar el sobreentrenamiento, aunque su tiempo fue el peor de los 3, con datos a gran escala y mejor ajustado puede ser la solución óptima.

08 · CONCLUSIONES

Lo que demuestra el taller



Se implementó un pipeline completo de ML sobre Spark, desde la carga en HDFS hasta la evaluación de modelos predictivos.



La Red Neuronal logró la mayor precisión ($R^2=0.9998$, $RMSE=0.0228$) por la naturaleza continua del WQI, aunque con un leve sobreajuste.



RF y GBT son los más coherentes con el procesamiento distribuido: operan distribuidos de extremo a extremo.



MLlib no ofrece un regresor neuronal distribuido; el Pandas UDF distribuye al menos la inferencia, no el entrenamiento.

La selección de un modelo a escala no debe basarse solo en precisión, sino en su capacidad de integrarse con la arquitectura distribuida subyacente.

09 · Referencias

Apache Spark Documentation. MLlib: Machine Learning Library.
<https://spark.apache.org/docs/latest/ml-guide.html>

Chollet, F. et al. (2015). Keras. <https://keras.io>

InTech Open. Water Quality Index as a Simple Indicator of Groundwater Quality.
<https://www.intechopen.com/chapters/69568>

Central Pollution Control Board, India. RiverIndia Water Quality Monitoring. <https://cpcb.nic.in>